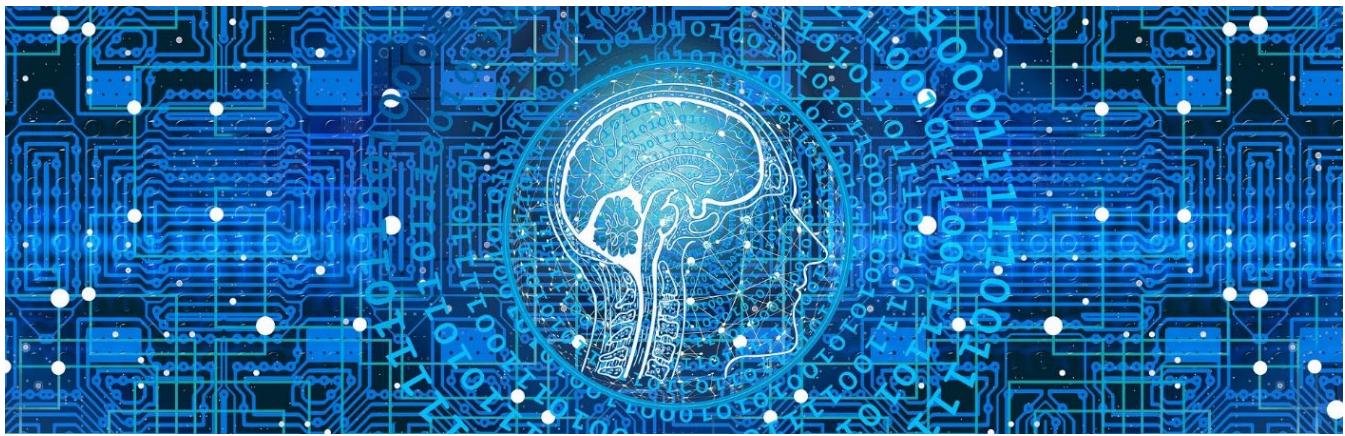

Data Science

9. Teil – Künstliche Intelligenz und Ethik

Vorlesung an der DHBW Stuttgart, basierend auf Skript von Dr. Falko Kötter



Inhalte der heutigen Vorlesung

- Künstliche Intelligenz – Definitionsversuch
- Ethik und Technologie
- Übung: Ethik im Alltag
- Ethische Fragen zu künstlicher Intelligenz
- Übung: Bias in Daten
- Crashkurs neuronale Netze
- Auswirkung von Bias auf Machine Learning



Warum ist KI überhaupt ein Thema?

1997 Deep Blue schlägt Kasparow

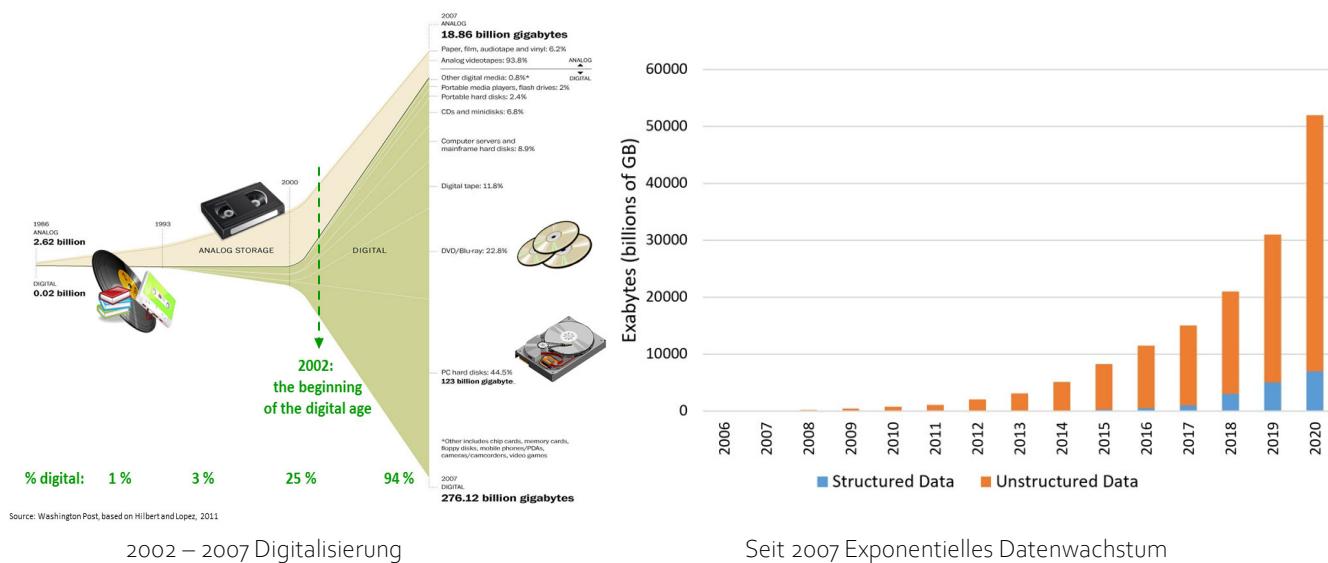


2017 Alpha Go schlägt Ke Jie



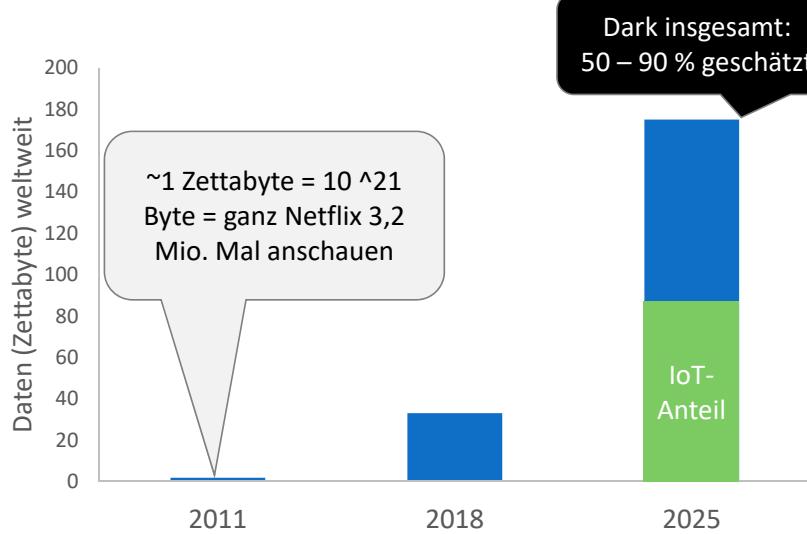
- Rechenleistung Deep Blue vs. Alpha Go Faktor 16.000
- Komplexität Schach vs. Go Faktor 10^{237}
- Fortschritt lässt sich allein durch schnellere Computer nicht erklären

Digitalisierung liefert den Treibstoff für KI



Datenwachstum

Immer mehr Daten in immer kürzerer Zeit



IDC Forecasts 2011 and 2018, beispielsweise verfügbar hier Andy Patrício:
<https://www.networkworld.com/article/3325397/storage/idc-expect-175-zettabytes-of-data-worldwide-by-2025.html>, 2018, zuletzt abgerufen 11.2.2019, Netflixvergleich z. B. hier: <http://frognow.com/internet/zettabyte/>. Kaffeemaschine: eigene Aufnahme

Definition - Was ist künstliche Intelligenz?

- Neuer KI Boom
 - Verfügbarkeit großer Datenmengen (Big Data, Internet)
 - Neue Verfahren (z. B. mächtigere neuronale Netze mit Deep Learning)
- Typische Aufgaben
 - Lernen, Planen und Entscheiden
 - Wahrnehmung und Spracherkennung
 - Robotik
- Keine einheitliche Definition -> Pragmatische Definition
 - KI erledigt Aufgaben, die zuvor menschliche Intelligenz erforderten
 - Aufgaben erfordern dynamische Entscheidungen
 - KI lernt anhand geleisteter Arbeit oder durch Erfahrungen, zukünftige Aufträge besser zu erledigen
- Grenzen zwischen Automatisierung und KI fließend



Künstliche Intelligenz und Machine Learning

- **Maschinelles Lernen (ML)**
 - Ist der Teil von künstlicher Intelligenz, die eine Menge von Trainingsdaten nutzt
- **Deep Learning**
 - ist der Teil von maschinellem Lernen, der mit künstlichen neuronalen Netzen mit vielen hidden layers arbeitet

Künstliche Intelligenz

Andere Methoden
(Heuristiken, Regeln,
Natural Language Processing,
Expertensysteme, Fuzzy Logic, ...)

Maschinelles Lernen

Deep learning

Anti-Definition – was ist künstliche Intelligenz nicht?

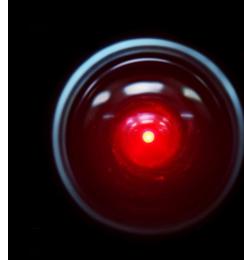
Künstliche Intelligenz ist KEINE Magie.

Künstliche Intelligenz hat KEIN inhärentes Verständnis der Aufgaben, die sie erledigt.

Künstliche Intelligenz hat KEIN Bewusstsein.

Künstliche Intelligenz entwickelt sich NICHT selbstständig weiter.

Künstliche Intelligenz kann NICHT schlauer sein als ihre Datenbasis.



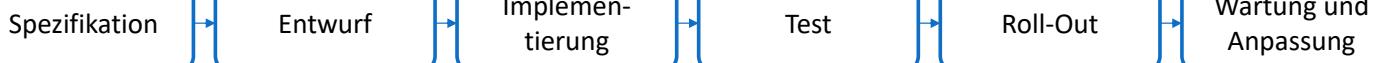
Images: ©Columbia Pictures
and Paramount Pictures

Images: ©Metro-Goldwyn-Mayer
und Paramount Pictures

Ob böse oder gut, solche KIs sind für's erste weiterhin Science Fiction.

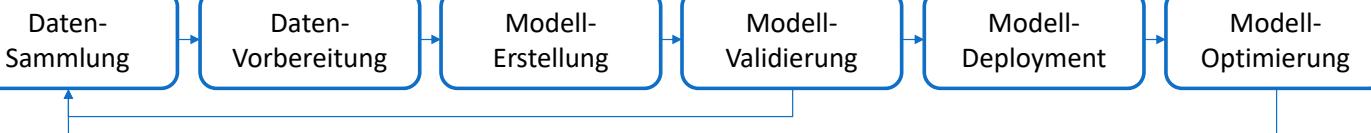
KI-Entwicklung als Software-Entwicklung

Vorgehen bei Softwareentwicklung (Wasserfall, Scrum, etc.)



Business Case

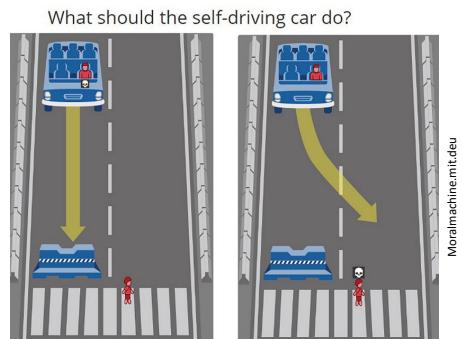
Vorgehen bei KI-Entwicklung (Machine Learning)



- **Softwareentwicklung:** Entwicklung von Algorithmen und Regeln, um automatisch Daten zu verarbeiten
- **Machine Learning:** Verarbeitung von Daten, um automatisch Algorithmen und Regeln zu entwickeln
- **Effizienzgewinn** durch automatische Erzeugung von »Spezifikation« und »Implementierung« als Modell
- **Verschiedene Berufsbilder?** Software-Ingenieur arbeitet konstruktiv, Data Scientist analytisch

Definition - Was ist Ethik?

- Ethik laut Duden
 - philosophische Disziplin oder einzelne Lehre, die das sittliche Verhalten des Menschen zum Gegenstand hat; Sittenlehre, Moralphilosophie
 - Gesamtheit sittlicher Normen und Maximen, die einer [verantwortungsbewussten] Einstellung zugrunde liegen
- Techniekthik
 - Befasst sich mit moralischen Folgen des Technologieeinsatzes
 - Abwägung von Nutzen und Schaden, Chancen und Gefahren, Eigennutz und Gemeinnutz
- Ethik und KI?
 - Maschinenethik - Moral autonom handelnder Technologie
 - Algorithmenethik – Gesellschaftliche Folgen algorithmischer Entscheidungen
 - Informationsethik – Moralischer Umgang mit Informationen und Daten



Asimovs Robotergesetze

1. Ein Roboter darf einem menschlichen Wesen keinen Schaden zufügen oder durch Untätigkeit zulassen, dass einem menschlichen Wesen Schaden zugefügt wird.

2. Ein Roboter muss den Befehlen gehorchen, die ihm von Menschen erteilt werden, es sei denn, dies würde gegen das erste Gebot verstößen.

3. Ein Roboter muss seine eigene Existenz schützen, solange solch ein Schutz nicht gegen das erste oder zweite Gebot verstößt.

Isaac Asimov „Runaround“

Übung – Ethik – relevant im Alltag als Informatiker?

- Sie betreiben eine Software für die Bearbeitung von Kundenanfragen – aus den Server-Logs geht hervor, wann ein, wann die Bearbeitung einer Anfrage beginnt und wann sie abgeschlossen ist – ihr Chef hätte gerne eine Aufstellung der Fälle samt Bearbeiter, Beginn-Zeitpunkt und Ende. Wie gehen Sie vor?
- Sie entdecken einen Bug in Ihrem Webportal, durch den für einen Kunden die Adressdaten anderer Kunden mit dem gleichen Vornamen sichtbar sind. Der Bug ist nur durch eine präzise Folge von Schritten reproduzierbar, die ein Nutzer nur sehr unwahrscheinlich durchführt. Was tun Sie, nachdem Sie den Bug behoben haben?
- Ein Kollege ist längere Zeit krank. Für einen wichtigen Kundentermin möchte sein Chef Einblick in das E-Mail-Postfach des erkrankten Kollegen. Was tun Sie?
- Für einen Webshop sollen Sie anhand von Kundendaten und vergangenen Bestellungen das Betrugsrisko einer Bestellung prognostizieren, die dann evtl. verweigert oder auf Vorkasse beschränkt wird. Zur Verfügung stehen vergangenes Verhalten (Bestellungen, Stornierungen, Rücksendungen, Zahlungen, ...), Name, Adresse, Nationalität, Geschlecht und Geburtsdatum. Sie können externe Datenquellen für Ihre Entscheidung hinzuziehen. Welche Daten verwenden Sie?



Diskussion untereinander

Danach Diskussion im Plenum

Ethische Richtlinien für Informatiker

- Ärzte haben den hippokratischen Eid (inzwischen modernisiert)
- Was haben Informatiker?
- Ethische Leitlinien der Gesellschaft für Informatiker (GI)
 - 12 Artikel, unter anderem Zivilcourage und soziale Verantwortung
 - IT soll zur Verbesserung der Lebensbedingungen beitragen
- ACM Code of Ethics
 - 3 Abschnitte: Generelle ethische Prinzipien, professionelle Verantwortung, und Führungsverhalten
 - Alle Menschen sind Teilhaber an der Informatik
 - Vermeiden von Schaden, Berücksichtigung von Privatsphäre, Ehrlichkeit, Diskriminierungsfreiheit, ...
- Tenets der Partnership on AI
 - KI soll der Menschheit nutzen
 - KI-Forschung muss alle Teile der Gesellschaft einbeziehen
 - KI muss Privatsphäre und Menschenrechte beachten
 - KI muss verständlich und Ergebnisse interpretierbar sein

»Bei meiner Aufnahme in den ärztl. Berufsstand gelobe ich feierlich, mein Leben in den Dienst der Menschlichkeit zu stellen. Ich werde meinen Beruf mit Gewissenhaftigkeit und Würde ausüben. Die Erhaltung u. Wiederherstellung der Gesundheit meiner Patienten soll oberstes Gebot meines Handelns sein. Ich werde alle mir anvertrauten Geheimnisse auch über den Tod des Patienten hinaus wahren. Ich werde mit allen meinen Kräften die Ehre und die edle Überlieferung des ärztlichen Berufes aufrechterhalten und bei der Ausübung meiner ärztlichen Pflichten keinen Unterschied machen weder nach Religion, Nationalität, Rasse noch nach Parteizugehörigkeit oder sozialer Stellung. Ich werde jedem Menschenleben von der Empfängnis an Ehrfurcht entgegenbringen und selbst unter Bedrohung meine ärztlichen Kunst nicht in Widerspruch zu den Geboten der Menschlichkeit anwenden. Ich werde meinen Lehrern u. Kollegen die schuldige Achtung erweisen. Dies alles verspreche ich feierlich auf meine Ehre.«

Genfer Gelöbnis des Weltärztekonsenses

Ethische Fragen in der künstlichen Intelligenz

- Gesamtgesellschaftliche Fragen, z.B.
 - Arbeitslosigkeit durch KI
 - Umgang mit künstlichen Lebensformen
 - Autonomieverlust der Menschheit
- Im Folgenden:
 - Ethische Dilemmata
 - Unbeabsichtigte Konsequenzen
 - Bias und Diskriminierung
 - Feedbackschleifen

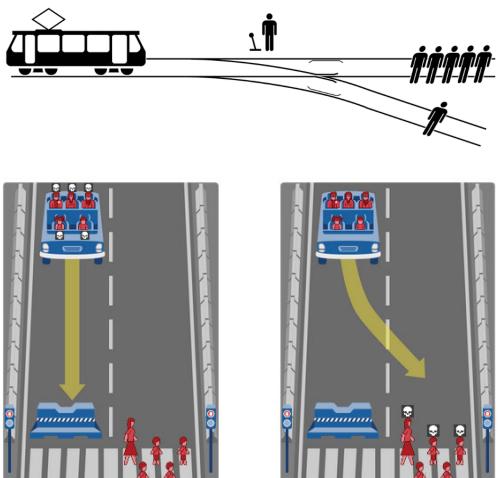
8 Ethical Questions in AI

-  **Bias:**
Is AI fair?
-  **Liability:**
Who is responsible for AI?
-  **Security:**
How do we protect access to AI from bad actors?
-  **Human Interaction:**
Will we stop talking to one another?
-  **Employment:**
Is AI getting rid of jobs?
-  **Wealth Inequality:**
Who benefits from AI?
-  **Power & Control:**
Who decides how to deploy AI?
-  **Robot Rights:**
Can AI suffer?

www.logikk.com  © copyright Logikk 2019

Maschinenethik – ethische Dilemmata in der Robotik

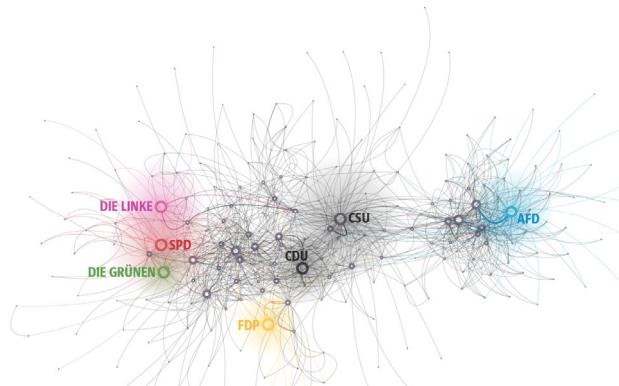
- Trolleyproblem
 - Gedankenexperiment in der Ethik
 - Bei Betätigung der Weiche wird ein Mensch überfahren, bei Nichtbetätigung sterben fünf
- Praktische Relevanz in der Robotik
 - Ein Roboter kann sehr schnell große Datenmengen verarbeiten und muss eine Entscheidung treffen
- Wie soll eine Maschine handeln, wenn sie zwischen zwei negativen Szenarien abwägen muss?
 - Im Extremfall: entscheiden, wer lebt und wer stirbt?
 - Aber auch:
 - Kandidatauswahl von Studienplätzen, Jobs, Therapieplätzen etc.
 - Verteilung von Ressourcen (wer bekommt ein Taxi?)
 - Verteilung von Lasten (wer zahlt wie viel Steuern?)



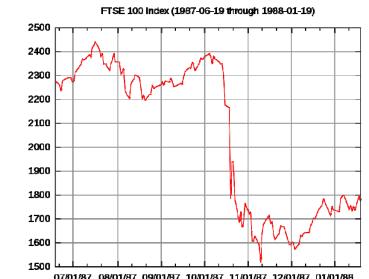
moralmachine.mit.edu erlaubt es, selbst Szenarien mit selbstfahrenden Autos zu beurteilen

Unbeabsichtigte Konsequenzen

- Nicht immer können die Konsequenzen neuer Technologien vorausgesehen werden
 - Positive und negative (Neben)effekte
 - Perversion - Gegenteiliger Effekte tritt ein
- Beispiele
 - Nebenwirkungen von Medikamenten
 - Antibiotika-Resistenz
- Technologiefolgenabschätzung
 - Systematische Analyse möglicher Folgen von Technologien
 - Betrachtet gesellschaftliche, ökonomische, ökologische und ethische Aspekte
- Collingridge-Dilemma
 - Je neuer die Technologie, desto schwerer die Abschätzung der Konsequenzen
 - Je etablierter die Technologie, desto schwerer die Änderung bzw. Kontrolle

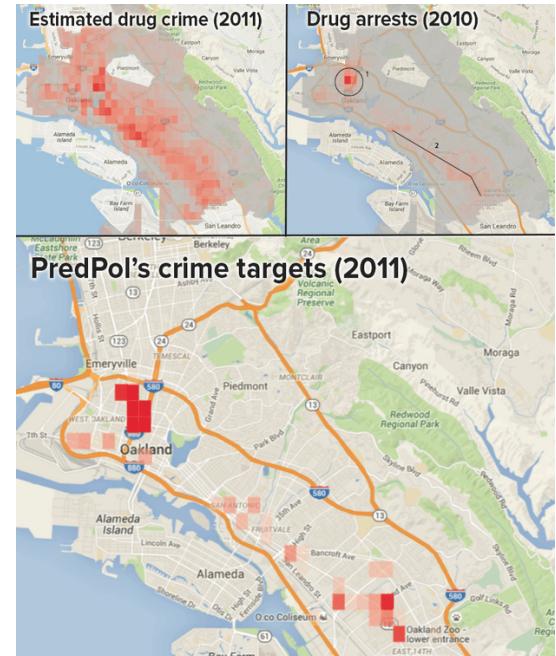


Quelle: <https://www.sueddeutsche.de/politik/politik-im-netz-in-der-rechten-schattenkammer-1.3495685>

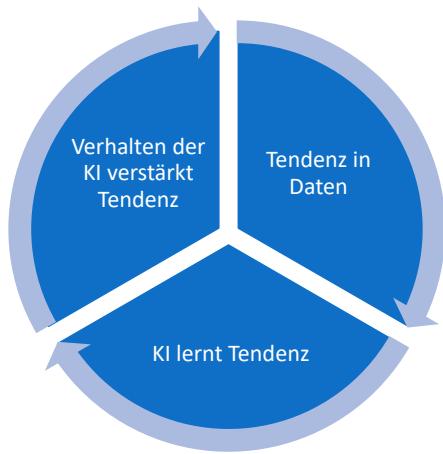


Feedbackschleifen

- Künstliche Intelligenz lernt von der Welt (auch von sich selbst)
- Dadurch kann KI gelernte Tendenzen verstärken
- Beispiel Predictive Policing
 - KI entscheidet, wo die Polizei kontrolliert
 - Wo kontrolliert wird, werden auch Verbrechen aufgedeckt - Dort wird noch stärker kontrolliert
- Beispiel Filterblasen
 - Webseite empfiehlt Content basierend auf dem bisher gesehenen zur Maximierung des Content-Konsums
 - KI empfiehlt ähnliches, was gesehen wurde
 - Konsument wird immer weiter zum Rand des politischen Spektrums geführt
 - Experiment: Videos über CIA und 9/11 führen schnell von Mainstream-News zu Verschwörungstheorien
- Beispiel Bonitätsprüfung
 - Abgelehnte Kreditanfragen wirken sich negativ auf Kreditwürdigkeit aus

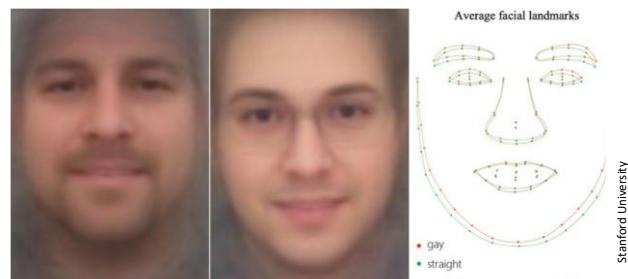


https://boingboing.net/2016/10/09/though-crime-happens-everywhere.html

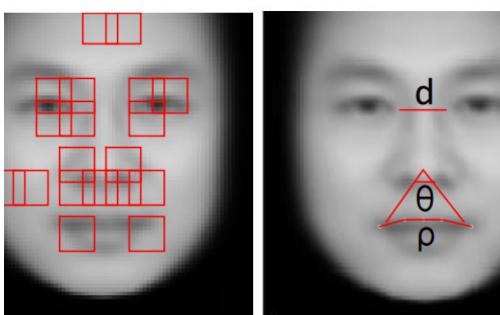


Biometrische Daten

- Idee, anhand von biometrischen Merkmalen Persönlichkeitsmerkmale ableiten zu können



Erkennung der sexuellen Orientierung mittels Gesichtserkennung



Unterscheidung von Fotos von Verbrechern und Nichtverbrechern

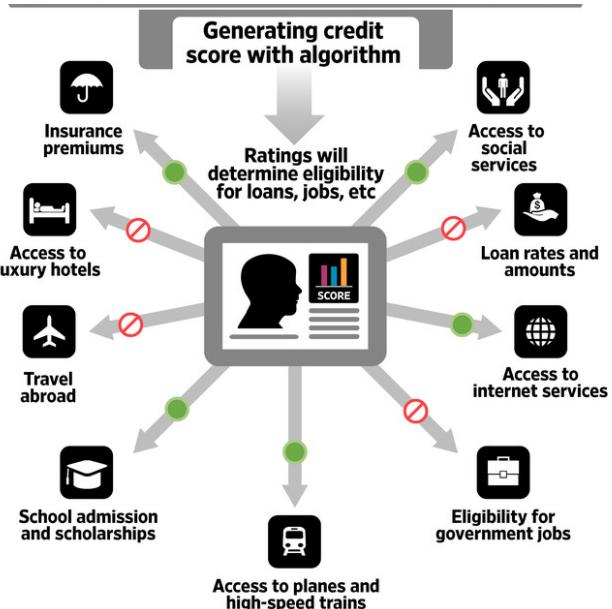
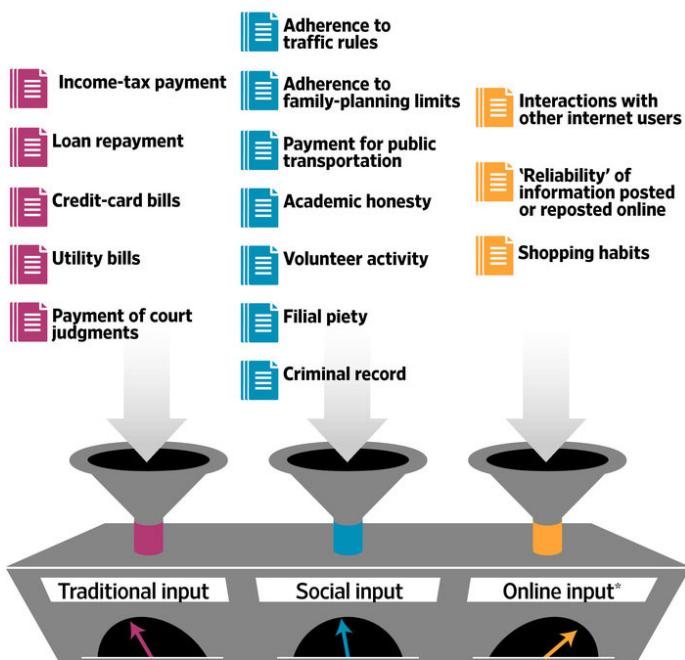


Fälschlich von Amazon KI als Verbrecher erkannte Kongressabgeordnete



Startup Faceception gibt vor, Terroristen anhand des Gesichts zu erkennen

Chinas Social Credit System



Quelle: Wall Street Journal

Wem gehören Daten?

Daten öffnen für die Wissenschaft und Gesellschaft zum Nutzen aller

„Vielleicht wird in Zukunft auch mit Gewalt um Daten gekämpft“

Nick Couldry, Kommunikationswissenschaftler <https://www.zeit.de/digital/datenschutz/2019-01/datenschutz-nick-couldry-datenkolonialismus-datenhandel>, zuletzt abgerufen am 8.2.2019

- **Wem gehören Daten?**
- Unternehmen gehen davon aus, dass Sie Daten generell zu kommerziellen Zwecken verwenden dürfen
- Sir Tim Berners-Lee: Jeder Nutzer sollte die Hoheit über seine Daten haben (Projekt Solid: „true data ownership as well as improved privacy“, <https://solid.mit.edu/>, zuletzt abgerufen am 16.2.2019)
- (Auch) viele Forschungsinstitutionen haben keine umfassenden Richtlinien für Open Data
- Beispiele
 - Kommunen sind bei der Verkehrsplanung etc. auf die Integration verschiedener Datentöpfe angewiesen
 - Deutsche Bahn: Erfolgreicher Hackathon mit 15 GB Daten (siehe dbmindbox.com/de/db-opendata-hackathons/, zuletzt abgerufen am 16.2.2019)
 - BPM Konferenz: Starke Empfehlung Daten von Veröffentlichungen zur Verfügung zu stellen
 - Neuroscience: Big Data Datenbanken für Neurowissenschaftler (Ferguson, Nielson, Cragin, Bandrowski und Martone, 2014)

Wilms, Stieglitz, Buchholz, Vogl und Rudolph, 2018 WILMS, KONSTANTIN ; STIEGLITZ, STEFAN ; BUCHHOLZ, ALINA ; VOGL, RAIMUND ; RUDOLPH, DOMINIK: Do Researchers Dream of Research Data Management? In: , 2018

Fraunhofer FOKUS, Fraunhofer IAIS und Fraunhofer IML, 2018 FRAUNHOFER FOKUS ; FRAUNHOFER IAIS ; FRAUNHOFER IML: Urbane Datenräume – Möglichkeiten von Datenaustausch und Zusammenarbeit im urbanen Raum. Berlin: Fraunhofer FOKUS, 2018

BPM 2019 Conference: https://bpm2019.ai.wu.ac.at/?page_id=234, zuletzt abgerufen am: 11.2.2019

Ferguson, Nielson, Cragin, Bandrowski und Martone, 2014 FERGUSON, ADAM R ; NIELSON, JESSICA L ; CRAGIN, MELISSA H ; BANDROWSKI, ANITA E ; MARTONE, MARYANN E: Big data from small data: data-sharing in the „long tail“ of neuroscience. In: *Nature Neuroscience* Bd. 17 (2014), Nr. 11, S. 1442–1447

Gefahr bei Veröffentlichung großer Datensätze

Deanonymisierung personenbezogener Daten

- Anonymisierung/Pseudonymisierung bei besonders großen Datensätzen ist schwierig, z. B.
 - Hashing auf zu kleiner Menge von Möglichkeiten (brute-force)
 - Externe Daten müssen berücksichtigt werden (unbekannt, da immer mehr verfügbar)
 - **Je größer die Datenmenge desto schwieriger wird es**
- Genaue Prüfung und Absicherung ist aufwendig (Beweis, dass keine Lücke vorhanden ist)



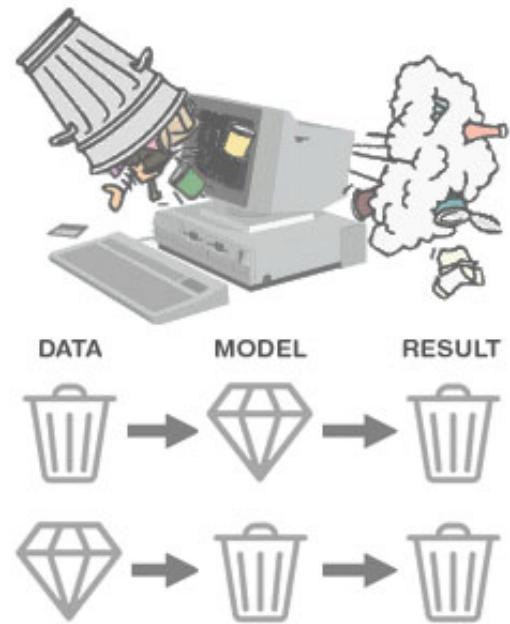
Narayanan und Shmatikov, 2008 NARAYANAN, ARVIND ; SHMATIKOV, VITALY: Robust De-anonymization of Large Datasets (How to Break Anonymity of the Netflix Prize Dataset). In: *2008 IEEE Symposium on Security and Privacy*, 2008

Douriez, Doraiswamy, Freire und Silva, 2016 DOURIEZ, MARIE ; DORAIWAMY, HARISH ; FREIRE, JULIANA ; SILVA, CLAUDIO T.: Anonymizing NYC Taxi Data: Does It Matter? In: *2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA)*: IEEE, 2016, S. 140–148 (auch Bildquelle)

Wer kennt den ersten Hauptsatz der Datenverarbeitung?

Erster Hauptsatz der Datenverarbeitung

- Garbage In, Garbage Out
- Machine Learning sucht kein korrektes Modell, sondern ein Modell, das die vorhandenen Daten möglichst gut wiedergibt
- Wie arbeitet also die ideale KI?
- „Wir machen das so, wie wir es immer schon gemacht haben!“



Quelle: <https://thedatacharon.com/more.net/2015/12/02/garbage-in-garbage-out/>

Vorurteile in Daten (Bias)

- Künstliche Intelligenz lernt aus vergangenen Daten
- Fehler und Vorurteile in diesen Daten werden übernommen und mittels künstlicher Intelligenz in Regeln gegossen
- So können bestehende gesellschaftliche Benachteiligungen weitergeführt und sogar noch verstärkt werden
- Beispiel COMPAS – Entscheidung über Bewährung
 - Voraussage der Rückfallwahrscheinlichkeit von Verbrechern mittels Machine Learning
 - Historische Diskriminierung von Minderheiten
 - KI nutzt Hautfarbe als Faktor zur Rückfallwahrscheinlichkeit
- Beispiel Recruiting
 - KI für Auswahl von Bewerbern bei Amazon
 - Bewerberauswahl aufgrund angenommener Bewerber sorgt für Homogenität
 - Als Diskriminierung von Frauen festgestellt wurde, wurde KI wieder abgeschafft

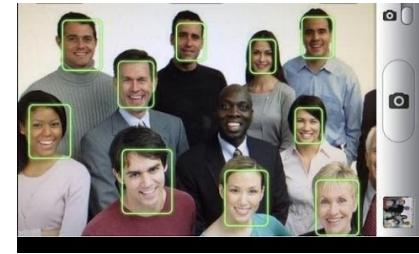


Quelle: 'COMPAS Software Results', Julia Angwin et al. (2016)

COMPAS berechnet Rückfallwahrscheinlichkeit für Verurteilungen vor amerikanischen Gerichten

Vorurteile in Daten (Bias) – Gegenmaßnahmen?

- Offenes Forschungsgebiet
- Technisch
 - Relevante Attribute entfernen
 - Aber: Korrelation beachten (z.B. ethnischer Hintergrund mit Wohnort)
 - Evtl. neue Klassifizierung ohne Attribute notwendig
 - Algorithmen mit nachvollziehbaren Entscheidungen verwenden
 - Trainiertes Modell reviewen
 - Mit allen relevanten Zielgruppen testen
- Organisatorisch
 - Eigene Verantwortung bewusst machen
 - DSGVO schränkt automatische Entscheidungen über Personen ein und gewährt u.a. Anfechtungsrecht, das Transparenz notwendig macht
 - Gesamtgesellschaftlicher Dialog

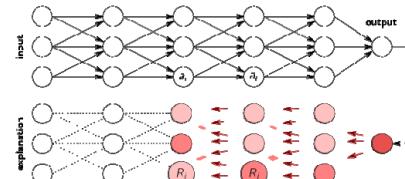


Bias in Gesichtserkennung

SA
LRP
It is the body's reaction to a strange environment. It appears to be induced partly to physical **changes** and part to mental distress. Some people are more prone to it than others, like some people are more prone to get sick on a roller coaster ride than others. The mental part is usually induced by a lack of clear information of which way is up in space. The shuttle is normally oriented with its cargo bay pointed towards Earth, so the Earth (or ground) is "above" the head of the astronauts. About 50% of the astronauts experience some form of motion sickness, and NASA has done numerous tests in space to try to see how to keep the number of occurrences down.

It is the body's reaction to a strange environment. It appears to be induced partly to physical **changes** and part to mental distress. Some people are more prone to it than others, like some people are more prone to get sick on a roller coaster ride than others. The mental part is usually induced by a lack of clear information of which way is up in space. The shuttle is normally oriented with its cargo bay pointed towards Earth, so the Earth (or ground) is "above" the head of the astronauts. About 50% of the astronauts experience some form of motion sickness, and NASA has done numerous tests in space to try to see how to keep the number of occurrences down.

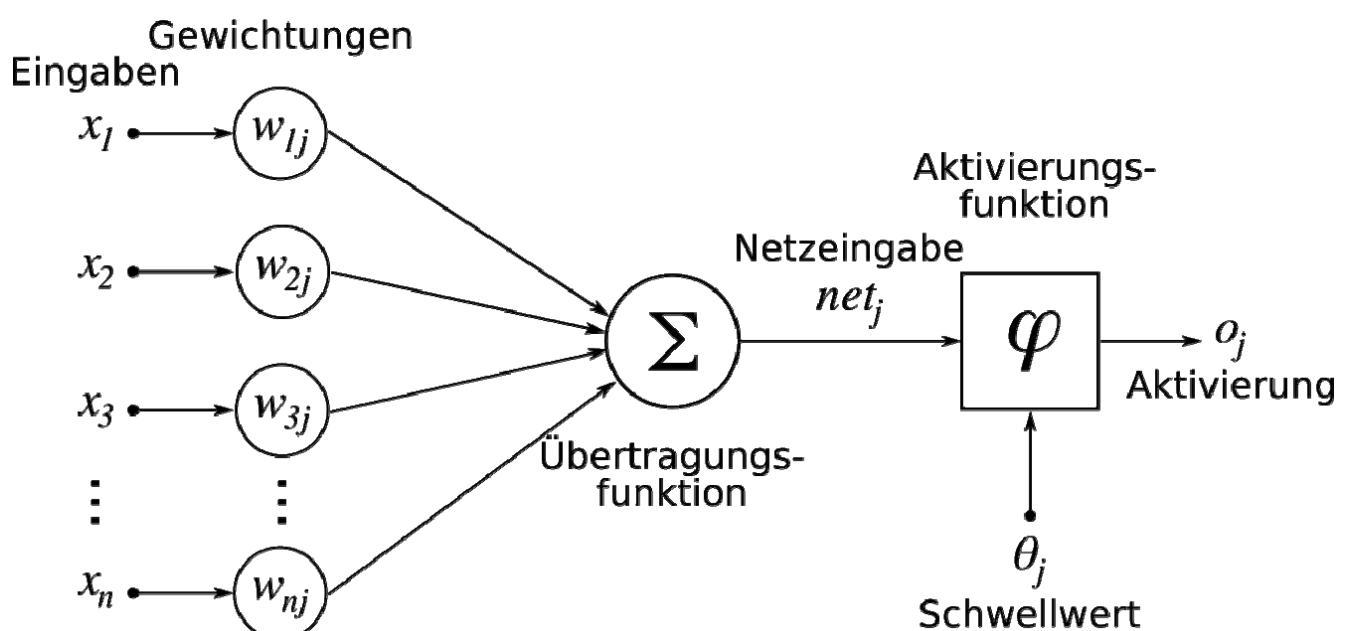
Highlight ausschlaggebender Worte für und gegen Klassifikation als medizinischer Artikel



Nach Entscheidung wird ein neuronales Netz rückwärts gelesen, um Begründung zu finden

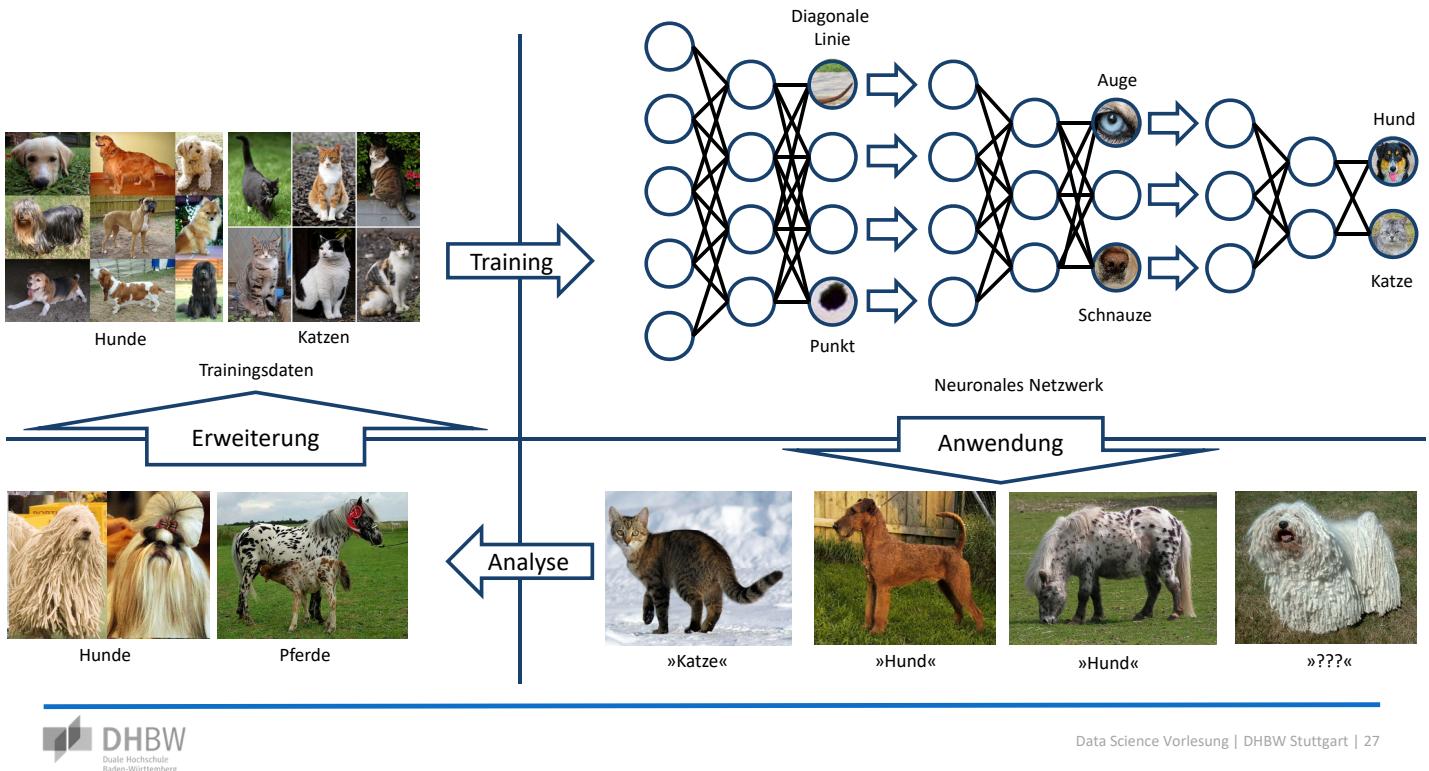
Data Science Vorlesung | DHBW Stuttgart | 25

Exkurs: Neuronale Netze



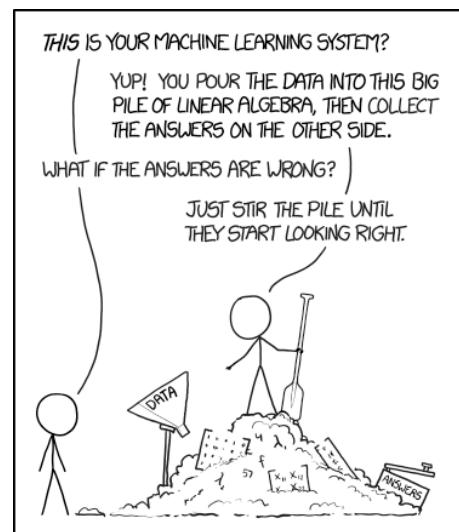
Exkurs: Neuronale Netze

Bilder: Wikimedia Commons



Exkurs: Neuronale Netze - Herausforderungen

- Neuronale Netze bilden das menschliche Gehirn nach
- Die Wissenschaft hat das menschliche Gehirn noch nicht verstanden
- Ähnlich dazu ist auch ein neuronales Netz praktisch eine Black Box
- Neuronale Netzwerke können Zusammenhänge entdecken, die Menschen nicht mehr artikulieren können
 - Formulieren Sie mal, wie man Hunde und Katzen unterscheidet..
- Algorithmen, die neuronale Netze erstellen haben hunderte von Stellschrauben
 - Level, Anzahl der Neuronen, Iterationen, ...
- Wie kann man erkennen, ob man Bias in den Ursprungsdaten entfernt hat?
 - Falls man überhaupt die Bias in den Ursprungsdaten erkennt...

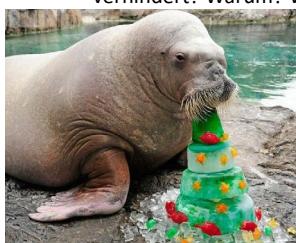


Quelle: <https://xkcd.com/1838/>

Übung – ein (erfundenes) Beispiel

- In einem weit entfernten Land leben **Walrösser** und **Om-Noms**
- Da beide Spezies sehr gefräßig sind, werden ständig neue **Fischrestaurants** und **Bonbonläden** eröffnet, wofür Noms und Walrösser einen **Kredit** aufnehmen
- Leider ist die Bank bei der **Kreditvergabe nicht ganz fair**
- Sie erhalten einen Datensatz zu Kreditanträgen, plus Information ob der Kredit gewährt und, falls gewährt, zurückgezahlt wurde
- **Aufgabe (Sie erhalten csv, und jupyter, Abgabe pdf, pass or fail):**
 - Untersuchen Sie den Datensatz auf mögliche Bias (Sie brauchen Diagramme, in Python oder einem anderen Tool, KEIN Machine Learning!)
 - Wie würden Sie den Bias verhindern?
 - Optional: Prüfen Sie in den Daten ob das reicht.
 - Optional: Trainieren Sie eine simple Vorhersage mit und ohne Bias. Haben Sie ihn verhindert? Warum? Warum nicht?

Bei der Kreditvergabe werden berücksichtigt:
Amount: Höhe des Kredits
Purpose: Zweck des Kredits (Candystore oder FishRestaurant)
Location: Ort des Geschäfts (Nomberg oder Walhafen)
Applicant: Antragssteller
Species: Spezies (Nom oder Walross)
Color: Farbe (Grün, Grau oder weiß)
Age: Alter (1-30 Jahre)
Residence: Wohnort (Nomberg oder Walhafen)
Defaulted Loans: Vergangene insolvente Kredite, die nicht zurückgezahlt wurden



Vielen Dank für Ihre Aufmerksamkeit!



Literaturliste (nur KI und Ethik)

- <http://maschinenethik.net/>
- <https://gi.de/ueber-uns/organisation/unsere-ethischen-leitlinien/>
- <https://www.acm.org/code-of-ethics>
- <http://nymag.com/intelligencer/2018/02/youtubes-recommendation-algorithm-favors-conspiracy-videos.html>
- <https://boingboing.net/2016/10/09/though-crime-happens-everywher.html>
- <https://www.nytimes.com/2017/10/09/science/stanford-sexual-orientation-study.html>
- <https://netzpolitik.org/2018/gesichtserkennung-von-amazon-verwechselte-us-abgeordnete-mit-verdaechtigen/>
- <https://www.sueddeutsche.de/politik/politik-im-netz-in-der-rechten-echokammer-1.3485685>
- <https://www.wired.com/2017/04/courts-using-ai-sentence-criminals-must-stop-now/>
- <https://www.reuters.com/article/us-amazon-com-jobs-automation-insight/amazon-scaps-secret-ai-recruiting-tool-that-showed-bias-against-women-idUSKCN1MK08G>
- <https://www.propublica.org/article/machine-bias-risk-assessments-in-criminal-sentencing>
 - Umfangreiche Analyse des COMPAS Datensets zur Rückfallquote
- <https://github.com/propublica/compas-analysis>
 - Jupyter Projekt zum selbst ausprobieren