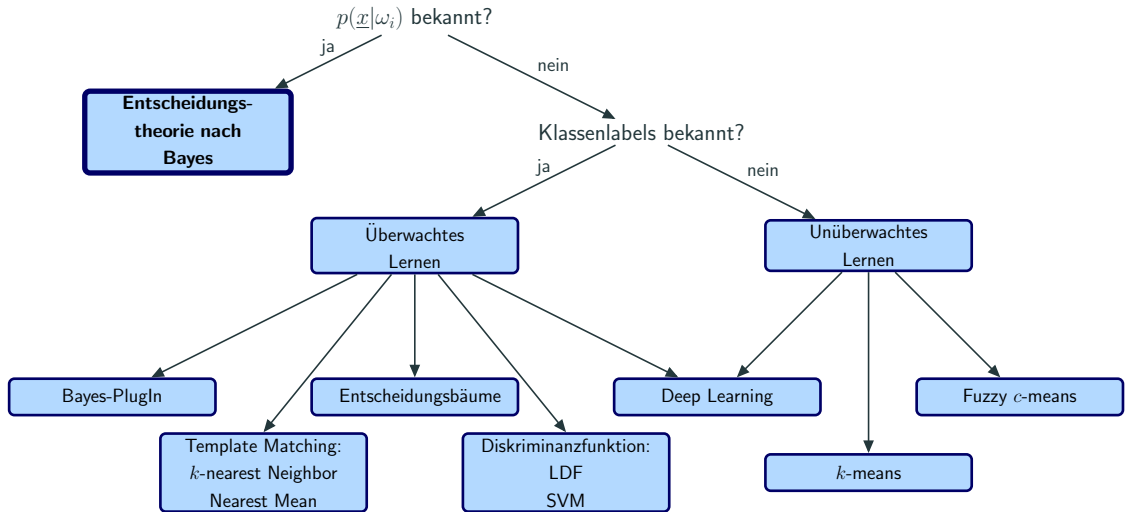


# Kapitel 4 - Probabilistische Entscheidungstheorie nach Bayes

---

Annika Liebgott

November 15, 2020



### Definitionen

$\omega \in \{\omega_1, \dots, \omega_c\}$ : unbekannte, zu schätzende Klasse (wahre Klasse)

$\underline{x} \in \mathbb{R}^d$ :  $d$ -dimensionaler Merkmalsvektor

$\hat{\omega}$ : geschätzte Klasse

### Definitionen

$\omega \in \{\omega_1, \dots, \omega_c\}$ : unbekannte, zu schätzende Klasse (wahre Klasse)

$\underline{x} \in \mathbb{R}^d$ :  $d$ -dimensionaler Merkmalsvektor

$\hat{\omega}$ : geschätzte Klasse

### Rückblick: Wahrscheinlichkeiten

$P(\omega = \omega_i) = P(\omega_i) = P_i$ : A-Priori-WK von Klasse  $\omega_i$ ,  $\sum_{i=1}^c P_i = 1$

$P(\omega_i | \underline{x})$ : A-Posteriori-WK

$P_{ij} = P(\hat{\omega} = \omega_i, \omega = \omega_j)$ : WK, dass  $\omega_i$  geschätzt wird, während  $\omega_j$  wahr ist

$\Rightarrow$  Verbundwahrscheinlichkeit,  $\sum_{i=1}^c \sum_{j=1}^c P_{ij} = 1$

### Rückblick: Verteilungen

$p(\underline{x}|\omega_i)$ : klassenabhängige PDF von  $\underline{x} \Rightarrow$  “Likelihood” von  $\underline{x}$

$p(\underline{x})$ : Marginalverteilung von  $\underline{x} \Rightarrow$  Evidenz von  $\underline{x}$

### Rückblick: Verteilungen

$p(\underline{x}|\omega_i)$ : klassenabhängige PDF von  $\underline{x} \Rightarrow$  "Likelihood" von  $\underline{x}$

$p(\underline{x})$ : Marginalverteilung von  $\underline{x} \Rightarrow$  Evidenz von  $\underline{x}$

### Rückblick: Bayes-Theorem

$$P(B|A) = \frac{P(A, B)}{P(A)} = \frac{P(A|B)P(B)}{P(A)}$$

$$P(B_j|A) = \frac{P(A|B_j)P(B_j)}{\sum_i P(A|B_i)P(B_i)}$$

## 4.1 - Minimum Bayesian Risk

---

# Minimum Bayesian Risk (MBR)-Klassifikator

**Grundidee:** Klasse  $\omega_i$ , für die Wert von BR minimal wird, wird ausgewählt

**Berechnung von  $\hat{\omega}$ :**

$$\hat{\omega}_{\text{BR}} = \arg \min_{\hat{\omega}} \text{BR} = \arg \min_{\hat{\omega}} R(\hat{\omega}|\underline{x}) = \arg \min_{\hat{\omega}} \sum_{j=1}^c l(\hat{\omega}(\underline{x}), \omega = \omega_j) \cdot P(\omega = \omega_j|\underline{x})$$
$$f_i(\underline{x}) = -R(\hat{\omega}(\underline{x}) = \omega_i|\underline{x}) \text{ bzw. } f_i(\underline{x}) = \sum_{j=1}^c l_{ij} P(\omega_j|\underline{x})$$

Vorgehensweise:

1. Berechne  $R(\hat{\omega}(\underline{x}) = \omega_i|\underline{x})$  für alle  $c$  möglichen Klassen.
2. Wähle die Klasse, aus der der kleinste Wert für  $R$  resultiert.



# Maximum A Posteriori (MAP)-Klassifikator

**Grundidee:** Klasse  $\omega_i$ , für die A-Posteriori-WK maximal wird, wird ausgewählt.

**Berechnung von  $\hat{\omega}$ :**

$$\hat{\omega}_{\text{MAP}} = \arg \max_{\omega_i} P(\omega_i | \underline{x})$$

$$f_i(\underline{x}) = P(\omega_i | \underline{x}) \text{ bzw. } f_i(\underline{x}) = p(\underline{x} | \omega_i) \cdot P(\omega_i)$$

Eigenschaften:

- Voraussetzung: 0/1-Loss
- $\min \text{BR} \hat{=} \max \text{A Posteriori}$

⇒ MAP ist ein Spezialfall von MBR!

# Maximum Likelihood (ML)-Klassifikator

**Grundidee:** Klasse  $\omega_i$ , für die Likelihood maximal wird, wird ausgewählt.

**Berechnung von  $\hat{\omega}$ :**

$$\hat{\omega}_{\text{ML}} = \arg \max_{\omega_i} p(\underline{x}|\omega_i)$$

$$f_i(\underline{x}) = p(\underline{x}|\omega_i)$$

Eigenschaften:

- Voraussetzung 1: 0/1-Loss
- Voraussetzung 2: gleiche A-Priori-WKs  $\Rightarrow P(\omega_j) = \frac{1}{c}$
- $\min \text{BR} \hat{=} \max \text{A Posteriori} \hat{=} \max \text{Likelihood}$

$\Rightarrow$  ML ist ein Spezialfall von MAP!

# Zusammenfassung: MBR, MAP und ML

## Zusammenhang:

$$\text{MBR} \xrightarrow{0/1\text{-Loss}} \text{MAP} \xrightarrow{P(\omega_j)=\frac{1}{c}} \text{ML}$$

Voraussetzung:

- ✓ Likelihood
- ✓ Loss
- ✓ A-Priori-Wahrscheinlichkeiten

Aber: Voraussetzungen sind nicht immer bekannt oder variabel.

**Frage:** Was tun, wenn Voraussetzungen unbekannt oder variabel sind?

## A-Priori-Wahrscheinlichkeiten: schwer zu bestimmen?

In manchen Fällen sind A-Priori-WKs einfach zu definieren, weil sie beispielsweise aus empirischen Untersuchungen bekannt oder statistisch berechenbar sind. In anderen Fällen sind sie nicht trivial.

**Altersklassifikation:** Soll das Bild einer in Deutschland lebenden Person einer Altersgruppe zugeordnet werden, stehen (theoretisch) aus Statistiken der Einwohnermeldeämter A-Priori-WKs zur Verfügung.

**Obstsortierung:** Je nach Wetterlage ändern sich die Mengenverhältnisse an Obst unterschiedlicher Sorten, die in Deutschland geerntet werden, von Jahr zu Jahr.

**Entscheidung in einem Mordfall:** Worauf sollen Wahrscheinlichkeiten basieren, ob ein Verdächtiger der Täter ist oder nicht?

**Militärische Zielerfassung:** Wie legt man Wahrscheinlichkeiten fest, ob eine Person im feindlichen Gebiet Feind oder Zivilist ist?

## 4.2 - Minimax

---

**Grundidee:** Minimierung des maximalen Bayesian Risks

**Bekannt:** Likelihood, Loss

**Unbekannt:** A-Priori-Wahrscheinlichkeiten

Vorgehen:

1. Optimierte Klassenwahrscheinlichkeiten  $P(\omega_i)$  so, dass MBR maximal wird
2. Wähle anschließend die Klasse  $\hat{\omega}$ , für die das in Schritt 1 berechnete MBR minimal ist

⇒ Wähle den Fall aus, für den der worst case am wenigsten schlimm ist.

## Berechnung von $\hat{\omega}$

$$\hat{\omega} = \arg \min_{\omega_i} \max_{P(\omega_i)} BR$$

Voraussetzung:

- ☒ Likelihood
- ☒ Loss
- ☐ A-Priori-Wahrscheinlichkeiten

## 4.3 - Neyman-Pearson

---



# Neyman-Pearson-Klassifikator

**Grundidee:** Klassifikator so designen, dass die False Alarm Rate ( $P_{\text{FA}}$ ) unterhalb eines festgelegten Schwellwerts  $\alpha$  liegt. Anderer Name: CFAR (Constant False Alarm Rate)

**Bekannt:** Likelihood

**Unbekannt:** A-Priori-Wahrscheinlichkeiten, Loss

2-Klassen-Problem:

$$\begin{bmatrix} 1 - P_{\text{FA}} & 1 - P_{\text{D}} \\ P_{\text{FA}} & P_{\text{D}} \end{bmatrix}$$

Vorgehen:

- maximiere die Detection Rate ( $P_{\text{D}}$ ) so, dass gleichzeitig  $P_{\text{FA}} \leq \alpha$  gilt
- Durchführung eines Likelihood-Ratio-Tests mit einem von  $\alpha$  abhängigem Schwellwert  $\gamma(\alpha)$

## Berechnung von $\hat{\omega}$

$$\hat{\omega} = \arg \max_{\omega_i} P_D$$
$$\text{s.t. } P_{FA} \leq \alpha$$

Voraussetzung:

- ☒ Likelihood
- ☐ Loss
- ☐ A-Priori-Wahrscheinlichkeiten